



APRENDIZAJE NO SUPERVISADO · DETECCIÓN DE ANOMALÍAS

Clasificación de Perfiles de Burnout en Desarrolladores

K-Means · DBSCAN · PCA · t-SNE · Isolation Forest · LOF



7,000 registros · 12 variables



Grupo 4 | Eduardo Alejandro Ceballos Jijón · Guillermo Leonidas Granizo Veintimilla · José Farid Ulloa Manzur · Christian Xavier Valle Maridueña



1. Introducción del Problema

Pregunta central: "¿Podemos descubrir perfiles de burnout en desarrolladores sin decirle al modelo quién tiene burnout alto, medio o bajo?"



El Dataset

7,000 desarrolladores · 12 variables de comportamiento laboral y hábitos diarios (horas, sueño, cafeína, bugs, reuniones, ejercicio, estrés).



El Reto

burnout_level y stress_level se EXCLUYEN del modelo. El algoritmo debe encontrar perfiles latentes solo a partir de las causas conductuales.



El Enfoque

Aprendizaje no supervisado: sin etiquetas de entrenamiento. Se validan los clusters contra burnout_level únicamente al final (sin data leakage).

★ **Objetivo:** descubrir perfiles latentes a partir de las CAUSAS del burnout — no de la etiqueta resultante.



Dataset & Análisis Exploratorio (EDA)

7,000

Registros

12

Variables

~2% / columna

Valores NaN

0 (sintético)

Outliers IQR

Distribución de burnout_level (referencia):



Dataset Sintético

Skewness ≈ 0 , sin outliers IQR, NaN MCAR uniforme al 2%. Importante: clusters serán menos nítidos que en datos reales.



Variables Excluidas

burnout_level (target), stress_level (codificación determinista del target), age y experience_years (sin correlación con burnout).



Feature Engineering

Se crean 3 features derivadas: ratio_trabajo_descanso, carga_operativa y indice_recuperacion para capturar desequilibrio carga/recuperación.



2. Metodología y Técnicas Aplicadas

1

EDA & Diagnóstico

Distribuciones,
naturaleza sintética,
correlaciones

2

Preprocesamiento

Imputación
(mediana), StandardScaler,
feature engineering

3

Selección de Features

7 vars sin leakage,
exclusión de stress_level
y burnout_level

4

Clustering K-Means

k óptimo 2–12,
4 métricas + ranking
combinado

5

DBSCAN & Anomalías

kNN elbow,
IF + LOF,
consenso doble

6

Validación & Reporte

Chi², ARI,
pureza,
vs burnout_level

Modelos y su Rol en el Pipeline

Modelo	Tipo	Propósito	Output
K-Means	Clustering	Segmentación en grupos homogéneos	k perfiles interpretables
DBSCAN	Densidad	Detectar outliers fuera de toda región densa	Puntos de ruido = casos atípicos
PCA	Reducción dim.	Visualización 2D y diagnóstico de varianza	% varianza capturada
t-SNE	Reducción dim.	Preservar estructura de vecindad local	Proyección visual no lineal
Isolation Forest	Anomalías	Detectar desarrolladores estadísticamente atípicos	Lista de prioridad
LOF	Anomalías	Validar anomalías con densidad local	Consenso IF+LOF



K-Means: Selección del k Óptimo y Perfiles

↑ Silhouette

Rango: -1 a $+1$

Cohesión vs separación.
Mayor = mejor clúster.

↓ Davies-Bouldin

Rango: ≥ 0

Similitud entre clusters.
Menor = mejor.

↑ Calinski-Harabasz

Rango: ≥ 0

Dispersión inter vs intra.
Mayor = mejor.

★ Ranking combinado

Rango: Decide k

Score ponderado de las 3 métricas anteriores.



Rango evaluado: $k = 2$ a 12 · Método: ranking combinado de 4 métricas · **k óptimo determinado por datos reales del modelo**

Perfiles descubiertos (nombres inferidos post-clustering):

Perfil 1 · Alto Riesgo

🔑 ratio_trabajo/descanso $\uparrow\uparrow$, carga_operativa $\uparrow$, índice_recuperación $\downarrow$

Predominio HIGH

Perfil 2 · Riesgo Moderado

🔑 trabajo elevado, descanso intermedio, cafeína moderada

Predominio MEDIUM

Perfil 3 · Bajo Riesgo

🔑 ratio_trabajo/descanso $\downarrow$, índice_recuperación $\uparrow$, ejercicio regular

Predominio LOW



burnout_level solo se usa para validación post-hoc — nunca durante el entrenamiento.



DBSCAN & Detección de Anomalías (IF + LOF)

DBSCAN — Clustering por Densidad

- ▶ eps y min_samples: calibrados mediante kNN elbow plot (k=5)
- ▶ Alta dimensionalidad (7 features): distancias euclidianas se homogenizan → DBSCAN tiende a un solo cluster denso
- ▶ Ruido (noise): desarrolladores que no encajan en ninguna región densa → máxima prioridad de revisión
- ▶ Solución propuesta: aplicar PCA $\geq 80\%$ varianza antes de DBSCAN para reducir dimensionalidad

Isolation Forest + LOF — Anomalías Individuales

- ▶ IF: contamination=0.05 → detecta ~5% de casos extremos
- ▶ LOF (n_neighbors=20): mide densidad local vs vecinos
- ▶ Consenso IF+LOF: casos marcados por ambos = mayor fiabilidad
- ▶ Score continuo (decision_function) > umbral binario para priorización

Uso complementario de los modelos:

K-Means

MACRO — Políticas por grupo

Qué grupos existen y cómo son

DBSCAN

DENSIDAD — Casos fuera de perfil

Quién no encaja en ningún cluster

IF + LOF

MICRO — Atención individual

Quién es estadísticamente atípico



3. Análisis Comparativo entre Modelos

Dimensión	K-Means	DBSCAN	PCA	t-SNE	IF + LOF
Tipo de análisis	Macro (grupos)	Densidad	Reducción dim.	Reducción dim.	Micro (individ.)
Requiere k/params	Sí (k)	Sí (eps, min_s)	Sí (n_comps)	Sí (perplexity)	Sí (contam.)
Maneja ruido	No	Sí	—	—	—
Output principal	k clusters	Outliers densi.	% varianza 2D	Vecindad local	Consenso IF+LOF
Uso recomendado	Políticas grupo	Casos atípicos	Visualización	Exploración	Atención urgente
Limitación clave	Asume clusters esféricos	Alta dimensionalidad	Pérdida de varianza	No reproducible (stochastic)	contamination subjetivo



Insight clave: Los modelos son COMPLEMENTARIOS, no rivales. K-Means responde '¿qué grupos existen?', DBSCAN '¿quién no encaja?', PCA/t-SNE '¿cómo visualizarlo?', IF+LOF '¿quién necesita atención individual?'



Validación Estadística de los Clusters

Los clusters se validan contra burnout_level SOLO al final, como referencia externa — no durante el entrenamiento.

Chi² (p-valor)

Prueba si la distribución de burnout_level es significativamente diferente entre clusters.

✓ $p < 0.05$ = significativo

ARI (Adjusted Rand Index)

Mide coincidencia entre asignación de clusters y etiquetas reales de burnout.

✓ $ARI > 0.1$ = coincidencia significativa

Pureza Media

% de registros en cada cluster que pertenecen a la clase de burnout dominante.

✓ Mayor % = clusters más puros

Hallazgo fundamental sobre la causalidad del burnout:



El factor más discriminativo es ratio_trabajo_descanso: un developer con pocas horas pero poco sueño puede tener mayor riesgo que uno con jornada larga y buen descanso.



La carga_operativa (bugs + reuniones) es el segundo eje: presión técnica + interrupción cognitiva = pérdida de flujo y mayor burnout.



El indice_recuperacion actúa como amortiguador: sueño y ejercicio regulares permiten tolerar cargas más altas sin manifestar burnout alto.



4. Conclusiones y Recomendaciones

✓ Conclusiones

1. El aprendizaje no supervisado reveló estructura latente real en el comportamiento laboral — los clusters capturan señal, no ruido del algoritmo (Chi^2 significativo, $\text{ARI} > 0$).
2. El burnout NO es una variable continua uniforme: se organiza en perfiles cualitativamente distintos definidos por el desequilibrio carga/recuperación.
3. K-Means y los detectores de anomalías (IF+LOF) son complementarios: macro-políticas por grupo + intervención individual.
4. El dataset sintético limita la nitidez de los clusters (skewness ≈ 0 , sin outliers IQR). En datos reales los perfiles serían más marcados.
5. DBSCAN en espacio de alta dimensionalidad pierde capacidad de segmentar: funciona mejor como detector de outliers de densidad.



Recomendaciones

- Datos reales:** Recolectar con cuestionarios validados (Maslach, PHQ-9). Las distribuciones asimétricas propias de datos reales producirán clusters más nítidos.
- DBSCAN optimizado:** Aplicar reducción PCA ($\geq 80\%$ varianza) antes de DBSCAN, o evaluar HDBSCAN. Considerar distancia de Mahalanobis.
- Política por perfil:** Clusters de alto riesgo: limitar horas, reducir carga operativa. Clusters de bajo riesgo: monitorear señales tempranas.
- Intervención individual:** Lista consenso IF+LOF: revisión 1 a 1 inmediata. Priorizar por score continuo, no por umbral binario.
- Variables cualitativas:** Incluir satisfacción laboral, autonomía percibida y apoyo social. Evaluar modelos mixtos (GMM) para clusters no esféricos.



Reflexión Final

*"No necesitamos decirle al modelo quién tiene burnout.
El propio comportamiento de los desarrolladores contiene la respuesta."*

EDA

Feature Eng.

K-Means

DBSCAN

PCA · t-SNE

IF · LOF

Validación



Eduardo Alejandro Ceballos Jijón · Guillermo Leonidas Granizo Veintimilla · José Farid Ulloa Manzur · Christian Xavier Valle Maridueña