



Clasificación de Perfiles de Burnout

en Desarrolladores de Software

Versión Técnica Ampliada

K-Means

DBSCAN

PCA/t-SNE

IF + LOF

Aprendizaje No Supervisado | Grupo 4 | UEES | 2026

- Eduardo Alejandro Ceballos Jijón
- Guillermo Leonidas Granizo Veintimilla
- José Farid Ulloa Manzur
- Christian Xavier Valle Maridueña

Agenda de la Presentación

01

Introducción y Dataset

Contexto, variables, decisiones de exclusión, FE

02

Preprocesamiento

Split, imputación, escalado adaptativo

03

K-Means — Detalle técnico

4 métricas, ranking, $k=2$, centroides, validación χ^2

04

DBSCAN — Detalle técnico

K-Distance, eps, maldición dimensionalidad, outliers

05

PCA y t-SNE

Varianza, loadings, fidelidad, comparativa

06

Isolation Forest + LOF

Scores, consenso, cruce DBSCAN, perfiles atípicos

07

Análisis Comparativo Global

Tabla multi-modelo, fortalezas, limitaciones

08

Conclusiones y Recomendaciones

Perfiles narrativos, acciones RRHH, limitaciones

01 | Introducción: Pregunta Central y Dataset

«Queremos descubrir perfiles de burnout sin decirle al modelo quién tiene burnout alto, medio o bajo»

7,000

Registros

Developer Burnout Dataset (Kaggle)

12

Variables raw

11 numéricas + 1 categórica

4

Variables modelo

Sin leakage ni redundancias

80/20

Split train/val

Sin estratificación por target

Distinción fundamental — causas vs. etiqueta

✗ **Supervisado:** aprende a predecir burnout_level dado X → requiere etiqueta en entrenamiento

✓ **No supervisado:** descubre grupos en X, luego verifica si coinciden con burnout_level (post-hoc)

01 | Selección de Variables y Feature Engineering

🚫 Variables Excluidas (razón técnica)

burnout_level

TARGET — leakage directo

stress_level

Codif. determinista 99.99% (regla 3 umbrales)

screen_time

$r = 0.93$ con daily_work_hours (redundancia)

commits_per_day

$r = -0.01$ con burnout (sin señal)

age / experience

$r < 0.02$ con todo (sin poder discriminatorio)

🌸 Espacio Final del Modelo (4 variables)

caffeine_intake

(original)

$r=+0.18$

ratio_trabajo_descanso

$daily_work_h \div sleep_h$

$r=+0.55$

carga_operativa

$bugs_per_day + meetings_per_day$

$r=+0.52$


indice_recuperacion

$sleep_hours + exercise_hours$

$r=-0.25$

✅ R^2 features nuevas $\rightarrow$ burnout_level ≈ 0.45 | Umbral leakage (stress_level): 0.83 $\rightarrow$ No hay leakage introducido

02 | Preprocesamiento: Pipeline Honesto



Imputación — Mediana (no Media)

- NaN por columna: ~140 (2.0%) — patrón MCAR sintético
- Features nuevas heredan ~280 NaN (2 componentes con NaN)
- Mediana preferida: produce enteros coherentes en variables discretas
- `fit()` SOLO en `X_train` → `transform()` en `X_train` y `X_val`
- Medianas impresas explícitamente para trazabilidad y auditoría

Diagnóstico Automático de Scaler

- Outliers IQR evaluados sobre train: 0 en las 4 variables
- Skewness máximo: 0.012 — distribución uniforme sintética
- Criterio: si `%outliers > 2%` o `|skew| > 1` → RobustScaler
- Resultado: StandardScaler seleccionado (ningún umbral superado)
- μ post-escalado train: ≈ 0.000 | $\sigma \approx 1.000$ (verificado)

¿Por qué Split en Clustering?

- Imputer y scaler calibrados solo con train → sin contaminación de val
- μ post-escalado val $\neq 0$ (señal de corrección metodológica correcta)
- `burnout_level` guardado separado — nunca toca el pipeline
- Validación del clustering sobre val: Δ Silhouette train/val < 0.05
- Con $n=7,000$ la distribución de clases es naturalmente balanceada

03 | K-Means: Fundamentos, Métricas y Selección de k

Algoritmo K-Means

1 Inicialización k-means++

Selecciona centroides iniciales con máxima dispersión para evitar convergencia local

2 Asignación

Cada punto → centroide más cercano (distancia euclidiana en espacio escalado)

3 Actualización

Nuevos centroides = media de todos los puntos de cada cluster

4 Convergencia

Repite hasta que asignaciones no cambien o max_iter=500 se alcance

```
n_clusters=2 | init='k-means++' | n_init=20 |  
max_iter=500 | random_state=42
```

4 Métricas para Selección de k (rango k=2..12)

Inercia (Método del Codo)

$$\sum_i \sum_{x \in C_i} ||x - \mu_i||^2$$

↓ al subir k → buscar punto de quiebre (2ª derivada)

k=2
~4,200

Silhouette Score

$$s(i) = (b(i) - a(i)) / \max(a(i), b(i))$$

a(i)=dist. intra-cluster, b(i)=dist. cluster más cercano · Rango [-1,+1]

k=2
~0.25

Davies-Bouldin Index

$$DB = (1/k) \sum_i \max_{j \neq i} [(\sigma_i + \sigma_j) / d(\mu_i, \mu_j)]$$

σ=dispersión interna, d=distancia entre centroides · Menor = mejor

k=2
~1.54

Calinski-Harabasz

$$CH = [SSB / (k-1)] / [SSW / (n-k)]$$

SSB=varianza inter-cluster, SSW=varianza intra-cluster · Mayor = mejor

k=2
~2,131

Ranking combinado: Score = (Sil_norm + DB_norm + CH_norm)/3 → k con menor Score = óptimo. Votación final ajustada (umbral DB < 0.05) → k=2

03 | K-Means: Centroides, Perfiles y Validación Estadística

Perfil Sobrecargado — Alto Riesgo

ratio_trabajo_descanso ↑ ALTO

Jornadas largas / poco sueño

carga_operativa ↑ ALTA

Muchos bugs + reuniones

indice_recuperacion ↓ BAJO

Poca recuperación física

caffeine_intake ↑ ALTO

Compensación energética

Perfil Equilibrado — Bajo Riesgo

ratio_trabajo_descanso ↓ BAJO

Jornadas equilibradas

carga_operativa ↓ BAJA

Carga técnica moderada

indice_recuperacion ↑ ALTO

Sueño + ejercicio regulares

caffeine_intake ↓ MOD.

Sin compensación artificial

Heatmap de Centroides (z-score):

Verde intenso → variable MUY por encima del promedio global

Rojo intenso → variable MUY por debajo del promedio global

Blanco/neutro → cercano al promedio (no característica distintiva)

✓ Test Chi² (validación estadística): $p < 0.05$ en TRAIN y VALIDACIÓN — los clusters diferencian significativamente burnout_level como referencia

04 | DBSCAN: Fundamentos, Parámetros y Maldición de la Dimensionalidad

Algoritmo DBSCAN

Core Point

Tiene $\geq \text{min_samples}$ vecinos dentro del radio eps . Define la frontera de un cluster.

Border Point

Dentro del radio eps de un core point, pero sin suficientes vecinos propios.

Noise Point

Etiqueta -1. No alcanzable desde ningún core point. → Outlier detectado.

eps (ϵ)

Radio de vecindad. Elegido por codo del K-Distance Graph (segunda derivada).

min_samples

Mínimo de vecinos para ser core. Heurística: $\geq n_{\text{dimensiones}} + 1 = 5$ (4 dims).

`eps=auto (K-Dist codo) | min_samples=4 | metric='euclidean'`

Maldición Dimensionalidad y Resultado

¿Por qué 1 solo cluster?

Con 4 dimensiones y distribución uniforme, las distancias euclidianas se homogeneizan → no hay zonas de baja densidad separadoras.

Exploración de eps (diagnóstico)

$\text{eps} \times 0.75, \times 0.50, \times 0.35$ probados automáticamente. Ninguno produjo múltiples clusters. → Densidad genuinamente uniforme confirmada.

~5% Puntos de ruido (-1)

Desarrolladores con perfiles atípicos. No clasificables en el cluster principal. Usados como señal de outliers para cruce IF/LOF.

Complementariedad con K-Means

DBSCAN confirma que los 2 perfiles K-Means son FRONTERAS MÉTRICAS, no densidades naturalmente separadas. K-Means impone particiones de forma correcta aquí.

05 | Reducción Dimensional: PCA y t-SNE — Análisis Técnico

PCA — Análisis de Componentes Principales

Objetivo

Transformar variables correlacionadas en componentes ortogonales que maximizan varianza explicada.

Varianza 2D

PC1 $\approx$ 23% + PC2 $\approx$ 12% = $\sim$ 35% total. Bajo pero esperado: 4 variables con correlaciones $r < 0.70 \rightarrow$ cada una aporta información genuinamente distinta.

PC1 (Dominante)

Cargado por ratio_trabajo_descanso y carga_operativa (+). $\rightarrow$ Eje de «Intensidad Laboral».

PC2

Cargado principalmente por indice_recuperacion. $\rightarrow$ Eje de «Capacidad de Recuperación».

Para 80% varianza

Se necesitan 3–4 componentes (según tabla acumulada del Paso 10.1). El espacio completo requiere 4 componentes para cobertura total.

Loadings ($|>0.4|$ =

dominante)

Cuantifican contribución de cada variable a cada PC. Permiten interpretar ejes en lenguaje de negocio.

t-SNE — Preservación de Vecindad Local

Objetivo

Minimizar divergencia KL entre distribuciones de similitud en espacio original y 2D. Preserva vecindad local, no varianza global.

perplexity=30

Número efectivo de vecinos locales considerados. Rango típico: 5–50. Valores altos $\rightarrow$ más estructura global capturada.

learning_rate=200

Controla velocidad de convergencia del gradiente descendente. Valor estándar para datasets medianos.

Ejes SIN interpretación

A diferencia de PCA, los ejes t-SNE no corresponden a combinaciones de variables. Solo sirven para visualización espacial.

Fidelidad al clustering

Re-clustering K-Means sobre t-SNE: N% puntos cambian de asignación vs M% en PCA. t-SNE suele ser más fiel a vecindad local.

Cuándo usar

Visualización exploratoria y detección de sub-grupos locales. NO para análisis interpretativo de variables.

PCA $\rightarrow$ analizar y comunicar (loadings interpretables) | t-SNE $\rightarrow$ explorar y visualizar (vecindad local) | Ambas técnicas son COMPLEMENTARIAS, no excluyentes

06 | Isolation Forest + LOF: Detección de Anomalías

Isolation Forest

Principio

Árboles de decisión aleatorios. Un outlier se aísla en pocas divisiones porque tiene valores extremos.

Score de anomalía

$s(x) = 2^{(-E[h(x)]/c(n))}$. $E[h(x)]$ =longitud de camino promedio. Mayor $s \rightarrow$ más anómalo.

contamination=0.05

Asume ~5% del dataset como anomalías. Ajustable según criterio de negocio.

Fortaleza

Escala linealmente $O(n \cdot \text{trees})$. No requiere escalar datos. Robusto en alta dimensión.

Resultado

~280 anomalías globales (5% train). Perfiles con valores extremos en alguna dimensión del modelo.

Local Outlier Factor (LOF)

Principio

Compara densidad local de cada punto con la de sus k vecinos. Un punto con densidad mucho menor es outlier.

$LOF(p) = \Sigma lrd(o)/lrd(p)$

lrd = densidad de alcanzabilidad local inversa. $LOF > 1$ indica anomalía relativa al entorno local.

$n_neighbors=20$

Vecinos para estimar densidad local. Mayor $\rightarrow$ más estable pero menos sensible a outliers locales muy localizados.

Fortaleza

Detecta outliers CONTEXTUALES: inusuales en su vecindad aunque no sean extremos globalmente.

Resultado

~280 anomalías locales (5% train). Suelen ser distintos a los de IF $\rightarrow$ perspectiva complementaria.

Estrategia de Consenso IF + LOF

Solo IF (~2-3%): Outlier global — revisión en contexto de equipo

Solo LOF (~2-3%): Outlier local — revisión con líder técnico directo

Consenso IF+LOF (~1-2%): MÁXIMA CONFIANZA — intervención individual urgente

Cruce DBSCAN ruido $\cap$ IF $\cap$ LOF = triple consenso $\rightarrow$ desarrolladores identificados por las 3 perspectivas metodológicas distintas (densidad + global + local)

07 | Análisis Comparativo: Todos los Modelos

Dimensión	K-Means	DBSCAN	PCA / t-SNE	IF + LOF
Tipo de modelo	Partitivo (distancias)	Densidad	Reducción lineal/no-lineal	Detección anomalías
Input	X_scaled (4 vars)	X_scaled (4 vars)	X_scaled (4 vars)	X_scaled (4 vars)
Output	2 clusters + centroides	1 bloque + ~5% ruido	2D coords (PCA: loadings)	Etiqueta 1/-1 + score
Parámetro clave	k=2 (4 métricas)	eps codo / min_s=4	n_components=2	contamination=0.05
Silhouette train	~0.25 ($\Delta val < 0.05$ )	N/A (1 cluster)	N/A	N/A
Detecta outliers	 No	 ~5% ruido	N/A	 ~5% (IF) / ~5% (LOF)
Resultado clave	2 perfiles accionables	Confirma fronteras métr.	35% varianza 2D / fidelidad	~1-2% consenso urgente
Uso recomendado	Políticas grupales RRHH	Outliers de densidad	Explorar/comunicar	Intervención individual

Todos los modelos usan el mismo espacio limpio (4 variables, sin leakage). Son complementarios: K-Means segmenta · DBSCAN valida fronteras · PCA/t-SNE visualiza · IF+LOF detecta

08 | Conclusiones y Recomendaciones

Hallazgo principal:

K-Means k=2 identificó 2 perfiles estructuralmente distintos sin usar burnout_level ni stress_level en entrenamiento. Test χ^2 $p < 0.05$ en train y val confirma que los clusters capturan patrones reales del comportamiento laboral.



Alto Riesgo

Reducir reuniones no esenciales

Política desconexión digital

Revisar gestión de bugs

Acceso a recursos de bienestar



Bajo Riesgo

Documentar prácticas exitosas

Programa de mentoría interna

Mantener equilibrio actual

Monitoreo preventivo periódico



Consenso IF+LOF

Revisión individual RRHH urgente

Entrevistas 1:1 prioritarias

No extrapolar perfiles grupales

Intervención ~1-2% dataset

Limitaciones:

(1) Dataset sintético (skewness≈0, 0 outliers IQR) → fronteras menos nítidas en datos reales · (2) Correlación moderada estructural en FE ($r \approx 0.47$ ratio ↔ índice, comparten sleep_h) · (3) DBSCAN no segmenta en este espacio (densidad uniforme) → propuesta: PCA previo ≥75% varianza · (4) Análisis estático → implementar como pipeline periódico para detectar migración entre perfiles

Gracias

Clasificación de Perfiles de Burnout en Desarrolladores

K-Means · DBSCAN · PCA / t-SNE · Isolation Forest · LOF

2 Perfiles

K-Means k=2

~5% Outliers

DBSCAN+IF+LOF

$p < 0.05$

Validación χ^2

0 Leakage

Pipeline limpio

~1-2% Consenso

IF+LOF urgente