



# Clasificación de Perfiles de Burnout

## en Desarrolladores de Software

---

K-Means

DBSCAN

IF + LOF

Machine Learning - Aprendizaje No Supervisado

Grupo 4 :

- Eduardo Alejandro Ceballos Jijón
- Guillermo Leonidas Granizo Veintimilla
- José Farid Ulloa Manzur
- Christian Xavier Valle Maridueña

# Agenda de la Presentación

01

## Introducción del problema

Contexto, pregunta central y dataset

02

## Metodología y técnicas

Pipeline completo, selección de variables, FE

03

## Resultados: K-Means

k óptimo, perfiles descubiertos, validación

04

## Resultados: DBSCAN + Anomalías

Clustering por densidad, IF + LOF, consenso

05

## Análisis comparativo de modelos

Tabla comparativa, PCA vs t-SNE

06

## Conclusiones y recomendaciones

Perfiles, limitaciones, acciones para RRHH

# 01 | Introducción del Problema

*«Queremos descubrir perfiles de burnout sin decirle al modelo quién tiene burnout alto, medio o bajo»*

7,000

Registros analizados

12

Variables del dataset

4

Variables del modelo (sin leakage)

## Enfoque no supervisado

El modelo aprende patrones de comportamiento. La etiqueta burnout\_level se usa SOLO como validación externa posterior — nunca como input de entrenamiento.

# 01 | Dataset: Variables y Decisiones de Exclusión

## ✓ Variables del Modelo (4)

### caffeine\_intake

Compensación energética

### ratio\_trabajo\_descanso

work\_h / sleep\_h → desequilibrio

### carga\_operativa

bugs + meetings → presión cognitiva

### indice\_recuperacion

sleep + exercise → factor protector

## ✗ Excluidas del Modelo (8)

### burnout\_level

TARGET — haría trampa

### stress\_level

Leakage 99.99% (codifica target)

### screen\_time

Redundante con daily\_work\_hours ( $r=0.93$ )

### age

Sin señal ( $r=0.01$  con burnout)

### experience\_years

Sin señal ( $r=-0.02$ )

### commits\_per\_day

No discrimina ningún cuartil ( $r=-0.01$ )

## 02 | Metodología: Pipeline Completo (11 Pasos)



### Sin leakage

burnout\_level y stress\_level excluidas. La etiqueta no toca el entrenamiento.

### Split honesto

80/20. Imputer y scaler calibrados solo con train. Val nunca contamina.

### Modelos complementarios

K-Means segmenta perfiles. DBSCAN + IF/LOF detectan excepciones.

## 02 | Feature Engineering: 3 Variables Compuestas

### ratio\_trabajo\_descanso

$\text{daily\_work\_hours} \div \text{sleep\_hours}$

Desequilibrio vida-trabajo. Alto = jornadas largas con poco sueño.

$r = +0.55$

### carga\_operativa

$\text{bugs\_per\_day} + \text{meetings\_per\_day}$

Presión técnica + social combinada. Frustración e interrupciones.

$r = +0.52$

### indice\_recuperacion

$\text{sleep\_hours} + \text{exercise\_hours}$

Capacidad de recuperación física. Consolida los 2 únicos factores protectores.

$r = -0.25$

✓ Verificación anti-leakage:  $R^2$  features nuevas  $\rightarrow$   $\text{burnout\_level} \approx 0.45$  (muy por debajo del umbral de  $\text{stress\_level}$ : 0.83). No hay leakage introducido.

## 03 | K-Means: k Óptimo = 2

**~0.25**

**Silhouette**

Separación moderada

**~1.54**

**Davies-Bouldin**

Menor = mejor

**~2,131**

**Calinski-H**

Mayor = mejor ratio

**$\Delta < 0.05$**

**Val vs Train**

Generaliza correctamente

### ¿Por qué k=2 y no k=3?

Silhouette baja al pasar a k=3 → fragmenta un grupo natural

Davies-Bouldin sube con k=3 → clusters más similares entre sí

Calinski-H cae con k=3 → pierde separación relativa

k=3 divide arbitrariamente uno de los dos grupos genuinos

## 03 | Los 2 Perfiles Descubiertos por K-Means

### Perfil Sobrecargado — Alto Riesgo

**ratio\_trabajo\_descanso** ↑ ALTO

Jornadas largas, poco sueño

**carga\_operativa** ↑ ALTA

Muchos bugs + reuniones

**indice\_recuperacion** ↓ BAJO

Poca recuperación física

**caffeine\_intake** ↑ ALTO

Compensación energética

### Perfil Equilibrado — Bajo Riesgo

**ratio\_trabajo\_descanso** ↓ BAJO

Jornadas equilibradas

**carga\_operativa** ↓ BAJA

Carga técnica moderada

**indice\_recuperacion** ↑ ALTO

Sueño + ejercicio regulares

**caffeine\_intake** ↓ MOD.

Sin compensación artificial

✓ Test  $\chi^2 p < 0.05$  en train y val — los clusters capturan diferencias reales de burnout\_level (referencia externa)



## 04 | DBSCAN + Detección de Anomalías: IF & LOF

### DBSCAN — Resultado y Significado

#### 1 cluster denso encontrado

El espacio de 4 variables tiene densidad uniforme — sin zonas de baja densidad que separen grupos.

#### ~5% de puntos de ruido

Desarrolladores con perfiles atípicos, no clasificables en ningún patrón.

#### ¿Por qué no es un error?

Confirma que los 2 perfiles K-Means son fronteras métricas válidas, no densidades separadas.

### IF + LOF — Estrategia de Consenso

#### Isolation Forest → ~5%

Outliers globales — fáciles de aislar en el espacio completo

#### LOF → ~5%

Outliers locales — inusuales respecto a sus vecinos inmediatos

#### Consenso IF+LOF → ~1-2%

Máxima confianza — anómalos desde ambas perspectivas

# 05 | Análisis Comparativo entre Modelos

| Dimensión        | K-Means                                                                                           | DBSCAN                                                                                       | IF + LOF                                                                                     |
|------------------|---------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------|
| Tipo             | Partitivo                                                                                         | Densidad                                                                                     | Detección anomalías                                                                          |
| Clusters         | 2 perfiles                                                                                        | 1 bloque + ~5% ruido                                                                         | N/A                                                                                          |
| Silhouette train | ~0.25                                                                                             | N/A (1 cluster)                                                                              | N/A                                                                                          |
| Generalización   | $\Delta < 0.05$  | N/A                                                                                          | N/A                                                                                          |
| Detecta outliers |  No              |  Sí (~5%) |  Sí (~5%) |
| Uso principal    | Perfiles grupales                                                                                 | Confirmar outliers                                                                           | Intervención ind.                                                                            |

PCA (~35% varianza 2D, ejes interpretables — PC1: intensidad laboral · PC2: recuperación) | t-SNE (mayor fidelidad vecindad local, ejes sin significado directo) → Complementarios

## 06 | Conclusiones y Recomendaciones

### Hallazgo principal:

K-Means  $k=2$  identificó 2 perfiles estructuralmente distintos sin usar burnout\_level en el entrenamiento. Test  $\chi^2 p < 0.05$  en train y validación confirma que los clusters capturan patrones reales.



### Alto Riesgo

- Reducir reuniones no esenciales
- Política de desconexión digital
- Revisar gestión de bugs
- Acceso a recursos de bienestar



### Bajo Riesgo

- Documentar prácticas exitosas
- Programa de mentoría interna
- Mantener equilibrio actual
- Monitoreo preventivo



### Consenso IF+LOF

- Revisión individual por RRHH
- Entrevistas 1:1 prioritarias
- No extrapolar perfiles grupales
- Intervención urgente (~1-2%)



Limitación: dataset sintético (skewness  $\approx 0$ , cero outliers IQR). Con datos reales de campo los clusters serán menos nítidos y los parámetros requerirán recalibración.

# Gracias

---

## Clasificación de Perfiles de Burnout en Desarrolladores

Aprendizaje No Supervisado · K-Means · DBSCAN · Isolation Forest · LOF

**2 Perfiles**

K-Means k=2

**~5% Outliers**

DBSCAN + IF/LOF

**$p < 0.05$**

Validación Chi<sup>2</sup>

**0 Leakage**

Pipeline limpio