



Clasificación de Perfiles de Burnout de Desarrolladores

Modelos No Supervisados | K-Means & DBSCAN | Detección de Anomalías



Developer Burnout Dataset | 7,000 registros | 12 variables

4

Algoritmos
Aplicados

5

Variables
del Modelo

2

Perfiles
Descubiertos

14

Duración del
Análisis (pasos)

? **Pregunta central:** "¿Podemos descubrir perfiles de burnout en desarrolladores sin decirle al modelo quién tiene burnout alto, medio o bajo?"

EL CONTEXTO

1

El burnout en desarrolladores es un problema creciente en la industria del software.

2

Los modelos supervisados requieren etiquetas ya conocidas → no sirven para detección temprana.

3

El aprendizaje no supervisado permite descubrir estructura oculta sin respuestas previas.

4

Se usaron las causas del burnout (hábitos, carga, estrés) NO la etiqueta resultante.

EL DATASET

7,000

registros de desarrolladores

12

variables de comportamiento

3 niveles

de burnout: Low / Medium / High

2%

de valores faltantes (NaN)

Sintético

distribuciones uniformes, sin outliers IQR



Objetivo: Descubrir perfiles latentes a partir de las CAUSAS del burnout, no de la etiqueta resultante. burnout_level fue EXCLUIDA del modelo.

❌ EXCLUIDAS DEL MODELO

burnout_level	TARGET — incluirla sería trampa
stress_level	Codif. determinista del target (99.99% accuracy)
age	Correlación nula con burnout ($r < 0.02$)
experience_years	Correlación nula con burnout ($r < 0.02$)
screen_time	Duplicado de daily_work_hours ($r = 0.93$)
commits_per_day	Sin poder discriminatorio ($r = -0.01$)

✅ ESPACIO FINAL DEL MODELO (5 Variables)

+0.18	caffeine_intake Compensación energética
+0.46	bugs_per_day Carga técnica directa
+0.50	ratio_trabajo_descanso daily_work_hours / sleep_hours
+0.48	carga_operativa bugs + meetings
-0.22	indice_recuperacion sleep + exercise

💡 Impacto del Feature Engineering en métricas de clustering (k=2)

Espacio	Silhouette	Davies-Bouldin	Calinski-H
7 variables con doble conteo	0.147	2.250	1,032
5 variables sin doble conteo 	0.252 (+71%)	1.541 (-31%)	2,131 (+106%)

01

EDA + Diagnóstico

7,000 registros · NaN 2% · Dataset sintético detectado

02

Feature Engineering

5 variables sin leakage · Sin doble conteo · $R^2=0.83$ bloqueado

03

Preprocesamiento

Split 80/20 · Imputer solo en train · StandardScaler adaptativo

04

K-Means (k=2)

4 métricas · Ranking combinado · Validación en val ($\Delta < 0.05$)



05

DBSCAN

K-Distance Graph · eps auto · 1 cluster + ~5% ruido/outliers

06

PCA + t-SNE

35% varianza en 2D · Loadings interpretables · Fidelidad comparada

07

IF + LOF

Consenso ~2.5% · Tres categorías de anomalía · Intervención prioritaria

Comparativa métricas: k=2 vs k=3

Métrica	k=2	k=3	Ganador
Silhouette (↑)	0.1451	0.1399	k=2 ✓
Davies-Bouldin (↓)	2.2649	1.9140	k=2 ≈
Calinski-H (↑)	1,032	987	k=2 ✓
Silhouette val Δ	< 0.05	—	Generaliza ✓

k=3 no agrega perfil genuino → fragmenta un grupo natural. k=2 respaldado por 3 de 4 métricas.


✓ Validación Chi² ($p < 0.05$): Los clusters diferencian significativamente burnout_level en TRAIN y VALIDACIÓN. El modelo generalizó correctamente (Δ Silhouette train/val < 0.05).

CLUSTER 0 — Alto Riesgo: Perfil Sobrecargado

ALTO	ratio_trabajo_descanso Jornadas largas vs poco sueño
ALTA	carga_operativa Bugs + reuniones elevados
ALTO	caffeine_intake Compensación energética extrema
BAJO	indice_recuperacion Poco sueño, sin ejercicio

CLUSTER 1 — Bajo Riesgo: Perfil Equilibrado

MOD.	ratio_trabajo_descanso Jornadas acotadas en relación al sueño
BAJA	carga_operativa Menos bugs y reuniones
MOD.	caffeine_intake Sin dependencia energética artificial
ALTO	indice_recuperacion Sueño y ejercicio regulares



DBSCAN — Clustering por Densidad

Parámetros	eps auto (K-Distance Graph) · min_samples = n_dims
Resultado	1 cluster denso + ~5% puntos de ruido/outliers
¿Por qué 1 cluster?	Distribución uniforme en 7D = maldición dimensionalidad
Exploración	eps × 0.75, × 0.50, × 0.35 → mismo resultado
Valor real	Detecta el ~5% de desarrolladores con perfil atípico

✓ K-Means segmenta perfiles → DBSCAN detecta excepciones. Modelos complementarios, no competidores.

⚠ ¿Por qué solo 35% en 2D? Las 7 variables tienen correlaciones bajas ($r < 0.70$). Cada variable aporta información genuinamente distinta → no hay compresión sin pérdida real.

PCA vs t-SNE — Reducción Dimensional

Dimensión	PCA	t-SNE
Tipo	Lineal	No lineal
Preserva	Varianza global	Vecindad local
Varianza 2D	~35%	N/A
Ejes interpretables	Sí (loadings)	No
Fidelidad clustering	Menor	Mayor ✓

PC1 y PC2: Ejes Interpretables (loadings reales)

PC1 (~23%) — Desequilibrio Carga/Rec.

ratio_trabajo_descanso (+) · carga_operativa (+) · indice_recuperacion (-)

PC2 (~12%) — Eficiencia vs Presión

bugs_per_day · meetings_per_day

Isolation Forest

Construye árboles de decisión aleatorios

Puntos que se aíslan rápido = anómalos

Detecta outliers GLOBALES

contamination = 0.05 $\rightarrow$ ~5% del dataset

Escala bien con datasets grandes

Local Outlier Factor (LOF)

Compara densidad local vs vecinos

Detecta outliers LOCALES (relativos al entorno)

n_neighbors = 20

contamination = 0.05 $\rightarrow$ ~5% del dataset

Inusual dentro de su propia vecindad

 **CONSENSO IF + LOF: Los dos métodos coinciden (~2–3%) $\rightarrow$ Mayor confianza diagnóstica**

 Solo IF | ~2.5%

Anómalo global, normal en su vecindad.
Menor prioridad.

 Solo LOF | ~2.5%

Normal global, inusual en su entorno.
Analizar contexto.

 IF + LOF | ~2–3%

Anómalo desde ambas perspectivas.
INTERVENCIÓN PRIORITARIA.

Tabla Comparativa Consolidada — Todos los Modelos

Dimensión	K-Means	DBSCAN	Isolation Forest	LOF
Paradigma	Partitivo	Densidad	Aislamiento	Densidad local
Requiere k	✔ Sí (k=2)	✗ No	✗ No	✗ No
Clusters/Grupos	2 perfiles	1 cluster + ruido	N/A	N/A
Anomalías/Ruido	0 (ninguno)	~5% ruido	~5% outliers	~5% outliers
Silhouette	0.1451 (train)	N/A	N/A	N/A
Gen. train/val	$\Delta < 0.05$ ✔	—	—	—
Propósito	Segmentar grupos	Detectar outliers	Outliers globales	Outliers locales
Uso organizacional	Políticas grupales	Alerta colectiva	Lista prioritaria	Lista prioritaria

Tabla Comparativa Consolidada — Todos los Modelos



Los modelos son COMPLEMENTARIOS — cada uno responde una pregunta distinta

K-Means

¿A qué perfil pertenece?

DBSCAN

¿Quién no encaja en ningún patrón?

IF + LOF

¿Quién es individualmente atípico?

PCA

¿Qué variables explican la variación?

01 El objetivo fue cumplido

Sin usar burnout_level ni stress_level, K-Means identificó 2 perfiles con diferencias estadísticamente significativas ($\chi^2 p < 0.05$ en train y validación).

02 k=2 es el número óptimo

3 de 4 métricas lo respaldan. k=3 fragmenta arbitrariamente uno de los dos grupos naturales sin agregar valor real al clustering.

03 El Feature Engineering fue clave

5 variables compuestas (sin doble conteo) mejoraron el Silhouette en +71% y el Calinski-H en +106% vs el espacio original.

04 Dataset sintético limita la generalización

Skewness ≈ 0 , cero outliers IQR, NaN exactamente al 2%. Los resultados no deben generalizarse directamente a datos reales.



Recomendaciones para trabajos futuros

1. Validar con datos reales de organizaciones de software ·
2. Explorar GMM para perfiles intermedios con probabilidades de pertenencia ·
3. Aplicar PCA previo a DBSCAN para reducir maldición de dimensionalidad ·
4. Incorporar variables contextuales: tipo empresa, lenguaje, modalidad de trabajo

El aprendizaje no supervisado

no necesita etiquetas para encontrar estructura real.

Con 5 variables de comportamiento y hábitos, el modelo reprodujo la separación de burnout que existe en la realidad — sin conocerla de antemano.



Detección Temprana

Variables observables en tiempo real
pueden anticipar el burnout



Feature Engineering

Diseñar bien el espacio de features
vale más que elegir el algoritmo



Modelos Complementarios

K-Means + DBSCAN + IF/LOF
ofrecen visión completa